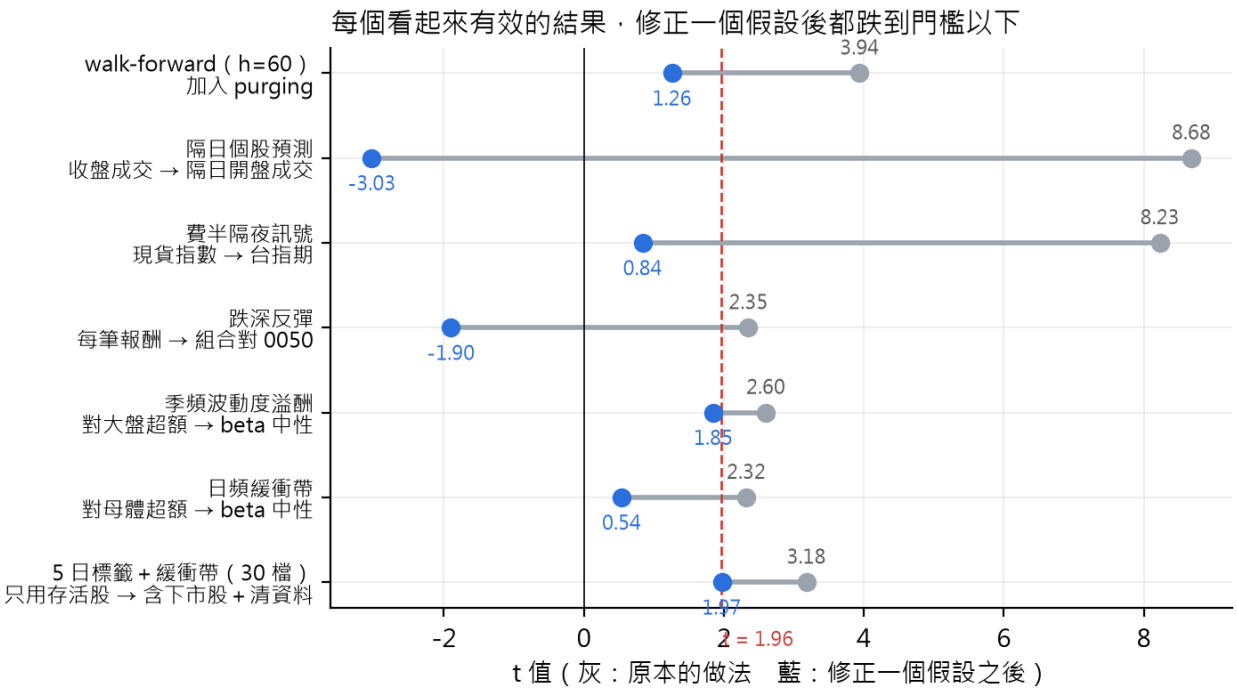
台股 DAViS 延伸研究：結果總整理

2026-10-15 | 涵蓋所有已完成的分析，標「修正後」的是補齊 2011 年資料後重跑的數字 | 完整內容見 results/研究結論總整理.md

主結論：用公開的價量、籌碼、文本資料，在台股找不到扣完成本、沖掉市場風險之後還顯著的選股 alpha。高波動股效應能穩定賺錢，但性質是 beta 大於 1 的風險補償，用台指期就能更便宜地複製。最接近 alpha 的是「5 日標籤 + 緩衝帶」：只用存活股時沖掉大盤後有 +14～22%（t 3.2～3.4），但放回下市股、再清掉 Yahoo 的假跳動後只剩 +8～10%，多重比較 RC p 0.087，不通過。跌深反彈改成實際投資人比較後，閒置資金放 0050 的 B 每年仍輸只買 0050 的 A 5～11 個百分點。研究的主要貢獻在方法論：找到十個會讓結果看起來更好的陷阱，並逐一量化。



圖一：七條看起來有效的路線，修正一個假設後的 t 值。紅線是 1.96。每一條都在修正一個假設後跌到門檻附近或以下。

一、方法論陷阱：十個會翻轉結論或灌水的錯誤

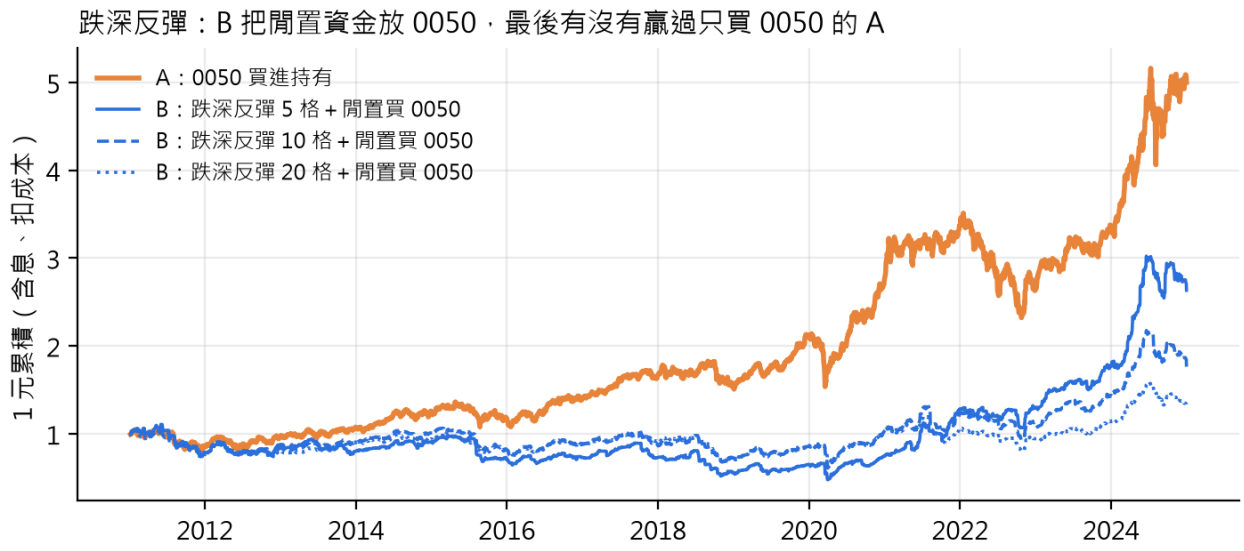
- **walk-forward 沒做 purging**：標籤是未來 h 日報酬，驗證窗最後 h 列的答案由測試期決定，h=60 時汙染 50%。修正後，年化超額從 19.85%（t 3.94、RC p 0.0002）降到 4.76%（t 1.26、RC p 0.34）。「拉長持有期就會賺」是洩漏造成的。
- **選股清單用當期市值**：拿 2024 年的排名決定 2011 年買什麼，修正後超額從 +7.20% 變成 -4.27%，11.5 個百分點全是偏誤。
- **0050 資料含假分割**：基準年化從 +0.01% 修正為 +11.58%，回撤從 -76% 修正為 -36%。
- **基本面欄位依位置硬套**：2015–2017 的本益比被存成收盤價，修正了 38.3 萬列。
- **回測只選「之後都有報價」的股票**（這次新發現）：等於事先知道誰會停牌、下市，高波動策略對大盤的超額從 +9.40% 降到 +7.35%，RC p 從 0.03 回到 0.049。
- **Yahoo 假跳動**（稽核發現）：376 筆超過漲跌幅的跳動，例如 1752 某天收盤是前一天的 101 倍；也有減資、現金增資沒調整。它們集中在高波動股，清掉後 5 日標籤策略的 RC p 從 0.045 變 0.087。
- **漲跌停門檻寫死 10%**（稽核發現）：2015-06 以前是 7%，2010–2014 的「鎖死不能買」過濾形同虛設。
- **特徵用了被往回調整的股數**（稽核發現）：股數水準帶有日後配股、減資的資訊，改用成交金額。
- **組合模擬的格數上限失效**（稽核發現）：同一天進場的股票共用一格，最多 52 檔擠一格。
- **成交不到的價格**：隔日預測用收盤價成交，年化 +161.6%（修正後 +175.3%）；改成隔日開盤成交就變成 -19.2%（t -3.12）。模型選中的股票有 9.4% 當天漲跌停，母體只有 1.1%，賺的是買不到、賣不掉的紙上價格。

二、文本與籌碼：原提案的資料軸全部否證

- 八種做法（逐檔 TF-IDF、主題模型、PTT 推噓、新聞直接預測、籌碼挑選、主題熱度等）沒有一種扣成本後有增益，逐檔 TF-IDF 甚至顯著有害。
- 原因是維度而不是資訊：每檔新聞中位數只有 131 則（六年），卻要擬合約 91 欄特徵。同一份 PTT 資料，100 欄的 TF-IDF 輸給純價量，9 欄推噓則持平。
- 主題配對（例如戰爭→鋼鐵）對衡量方式非常敏感，換個規格就跌出前 12 名，應視為資料窺探。

三、跌深反彈：效應真實，但組合層級輸給 0050

- 新聞或起跌後 5 日內跌 8%、止跌時進場。稽核後每筆淨報酬 +0.34%（群集 t 2.41），但排除 2020–2021 後只剩 +0.00%（t 1.57）。
- 市值前 50 大更強（+3.84%，t 5.61），所以不是生存者偏誤造成的。
- 舊的組合層級測試（10 格 +3.79%、20 格 +0.73%）有格數上限的 bug，0050 也不含息，已由下面的兩位投資人對照取代。
- 等反轉訊號才進場會讓超額歸零，相對止跌就進場最好。
- **兩位投資人對照（2011–2024，圖五）**：A 期初全買 0050 一路抱；B 也從 0050 開始，有訊號就賣一格 0050 買股票，出場後立刻買回 0050。兩邊都含 0050 股利（約 3% / 年），切換付手續費與 ETF 證交稅。
- 結果：A 1 元變 5.00 倍（年化 +12.6%）；B 5 / 10 / 20 格只有 2.63 / 1.76 / 1.30 倍（+7.4% / +4.3% / +2.0%），每年少 5～11 個百分點，10 格版 14 年只贏 2 年。訊號太多，B 平均 7～8 成資金都在個股上，放棄了 0050 的股利與權值股漲幅，每筆反彈賺的 +0.34% 補不回來。



圖五：跌深反彈兩位投資人。橘線 A 只買 0050，藍線 B 用跌深反彈、閒置資金放 0050（5 / 10 / 20 格）。含息、扣成本。

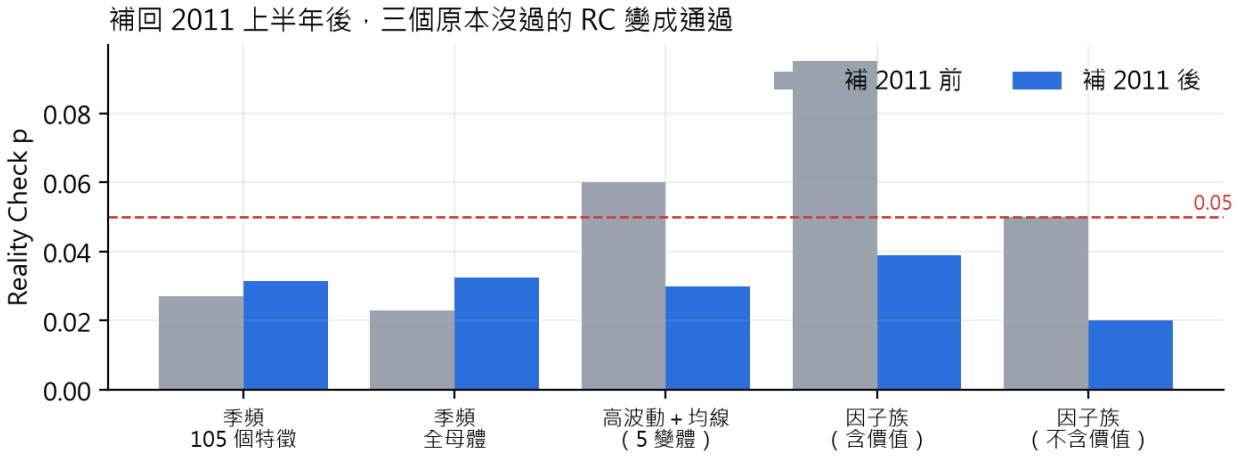
四、費半隔夜：異象在交易不到的地方

- 費半前一晚的漲跌，對台股現貨「開盤後到收盤」有預測力，2018–2024 強弱組差 +0.498%（t 8.23），而且越來越強（台積電權重從 10% 升到 35%）。
- 但台指期 8:45 開盤就完全反映了（日盤盤中差 +0.033%，t 0.84），連夜盤出現前也是。要賺現貨的殘差得買一籃子個股，成本 0.39% 比訊號還大。
- 韓股、日股前日收盤沒有預測力（相關 0.03～0.07）。

五、唯一穩定的效應：橫斷面波動度溢酬（性質是 beta）

- 規則：每季在成交金額前 250 名中，買 60 日波動最高的 30 檔等權持有。
- **2003 起的長期版（每 63 個交易日換股，稽核後）**：對大盤超額 +7.33%（t 2.17），對母體等權 +5.12%（t 2.23），低波動組 -6.24%（t -3.19），兩邊對稱。RC p 0.061～0.053、SPA p 0.045～0.048，**邊緣**。
- **這個版本的 RC p 來回了三次**：補 2011 後從 0.06 掉到 0.02～0.03（圖二）；修掉「只選之後都有報價的股票」的前視後回到 0.049；清掉 Yahoo 假跳動後 0.061～0.053。結論對資料細節很敏感，本身就是發現。

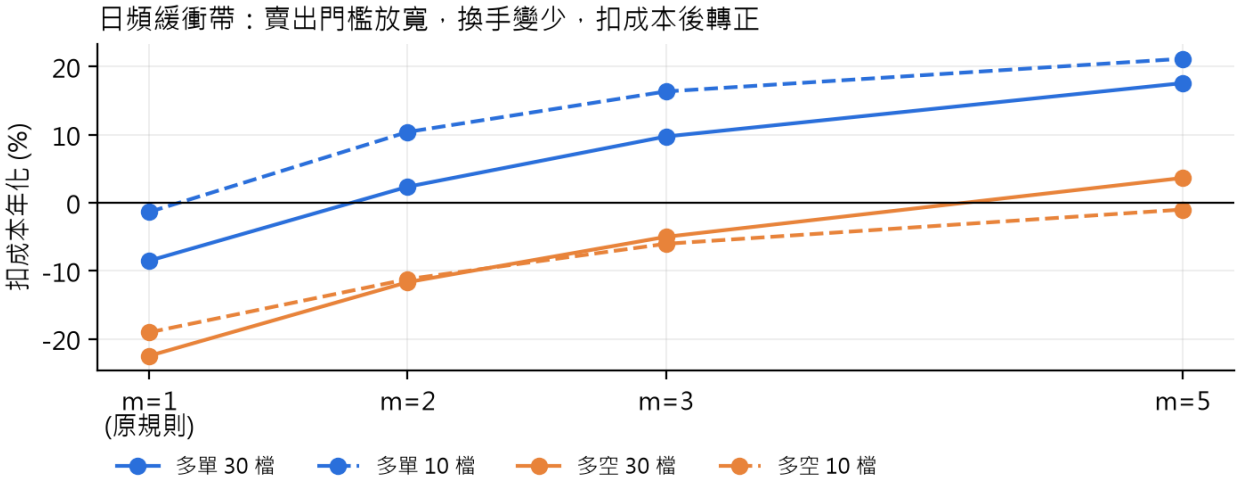
- **季頻版（105 個特徵篩選，稽核後）**：勝出的仍是 60 日波動度，RC p 0.037、SPA p 0.015，通過。固定 30 檔年化 +21.94%。
- **但它是 beta**：滾動 beta 中位數 1.24；beta 中性後 +7.84%（t 1.87）不顯著；把大盤放大到同樣波動度後，策略反而少 1.43%（t 0.25）。整個策略可以用台指期複製。
- **加回現金股利**：高波動股殖利率 2.1%，低波動股 4.3%（圖四），對母體超額從 +11.8% 縮到 +10.2%，仍顯著（t 2.36）。
- **生存者偏誤**：把下市股放回去（價格已換算成同一基準），年化只少 0.4～1.2 個百分點。
- **趨勢過濾（大盤在 120 日線上才持有）**：回撤從 -72.8% 降到 -39.2%，但修正後夏普 0.79 反而低於不過濾的 0.81。2011 年 3～7 月大盤在均線附近反覆穿越 17 次，過濾版那年 -18.8%。



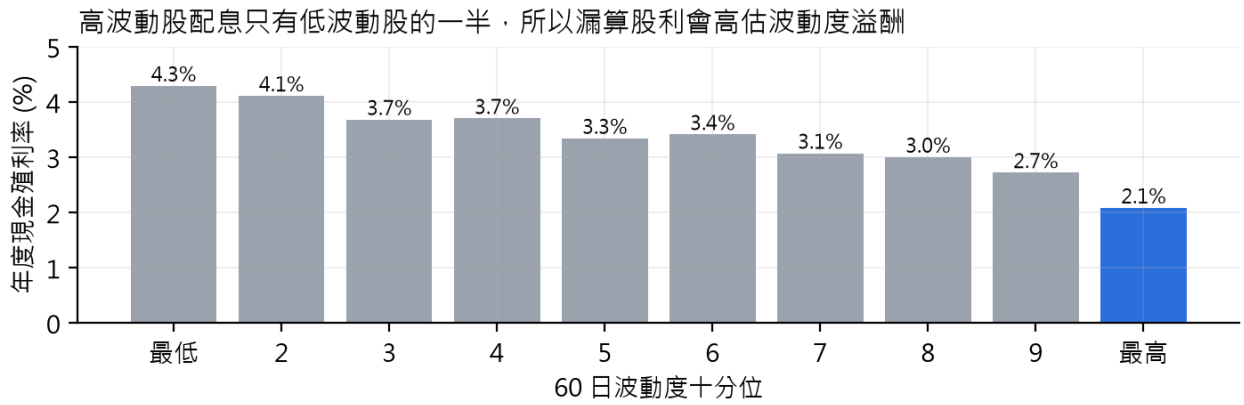
圖二：只補了 8 個月的資料，RC p 就從 0.06 掉到 0.02～0.03，代表它對樣本期很敏感。之後修正前視篩選、清掉假跳動，高波動＋均線那組又回到 0.053～0.061。

六、日頻預測：瓶頸是成本，不是預測力

- 105 個特徵的隔日模型，IC +0.069（t 31），多空 10 檔零成本年化 +70%，選股能力是真的。但每天換股，成本吃光毛利，誠實假設下 4 組全為負。
- **加緩衝帶**（掉出前 m×n 名才賣，16 組規格事前固定）：多單 30 檔、m=5 換手降六成，扣成本年化 **+17.6%**，RC p 0.027、SPA p 0.034（圖三）。
- **但四道驗證拆穿它**：beta 1.05，對大盤 alpha t 0.80，beta 中性後 t 0.54；每邊加 0.05% 滑價超額就歸零；2020–2023 連四年輸母體；完全不賣也有 +15%，賺的是持有本身。
- 同一個模型做多空只剩 +3.6%，差的部分就是大盤漲幅被放空腿抵銷掉的。



圖三：日頻緩衝帶。m 是賣出門檻的倍數，m=1 是原規則。



圖四：按 60 日波動度十分位，各組的年度現金殖利率。

六之二、預測期間對齊持有期間：最接近 alpha，但最後沒有通過

- 緩衝帶失敗的原因是模型學「明天」，卻被拿去抱好幾天。改用 1 / 5 / 20 日報酬當標籤重新訓練，純做多 10 / 30 檔、緩衝 m=1 / 5，共 12 組規格事前寫死，主指標是用台指期沖掉 beta 後的報酬。
- **5 日標籤、m=5（稽核前、只用存活股）**：10 檔扣成本年化 +44.5%，對沖後 +21.8%（t 3.39，前後半 t 2.85 / 2.01）；30 檔 +32.4%，對沖後 +14.0%（t 3.18）。12 組一起檢定 **RC p 0.0035、SPA p 0.0020**。所有 m=1 的版本都失敗。
- **累積報酬**：稽核前只用存活股（2014-01～2026-10）1 元變成 10 檔 91.8 倍、30 檔 31.3 倍；含下市股 50.5、21.5 倍；**稽核後含下市股（圖六）32.4、16.0 倍**（年化 +33.5%、+25.8%）。同期加權指數 5.4 倍（+15.0%），含息扣費的 0050 近似 7.8 倍（+18.6%）。
- **五道驗證都過（稽核前、只用存活股）**：單邊滑價 0.10% 仍有 +11.5% / +8.5%（t 2.11 / 2.12），0.20% 才不顯著；剔除開盤漲停買不到的進場幾乎沒影響；個股日報酬截在 ±11% 後 +17.0% / +11.5%；控制高波動因子與等權減大盤後仍有 +16.6% / +10.3%。
- **含息對沖（稽核前、只用存活股）**：放空台指期要付大盤股利（期貨價約等於現貨扣股利），持股的現金股利則加回（10 檔約 2.4% / 年、30 檔約 3.2% / 年），再扣期貨轉倉 0.2% / 年。大盤殖利率假設 3.5% 時，對沖後 10 檔 +19.3%（t 3.08）、30 檔 +13.0%（t 3.00）。
- **生存者偏誤是最大的扣減項**：把 70 家下市股放進價格、母體排名與特徵庫重跑後，對沖後 10 檔從 +21.8%（t 3.39）掉到 +12.7%（t 1.93），30 檔從 +14.0%（t 3.18）掉到 +10.8%（t 2.54），RC p 0.045。
- **稽核後不通過**：清掉 Yahoo 假跳動、修正漲跌停門檻與成交量特徵後重跑，含下市股版本對沖後10 檔 +10.3%（t 1.65）、30 檔 +7.9%（t 1.97），**12 組 RC p 0.087、SPA p 0.087**。累積報酬 10 檔 32.4 倍、30 檔 16.0 倍（圖六），看起來仍遠勝 0050 的 7.8 倍，但那主要來自 beta 1.1～1.2、中小型股曝險與大多頭期間的複利，不是可交易的 alpha。
- **怎麼寫**：「標籤期間 = 持有期間」加「低換手」是讓日頻預測力最接近可交易的做法，但經生存者偏誤與資料清理後不顯著；它的優勢有一部分來自資料源的假跳動。



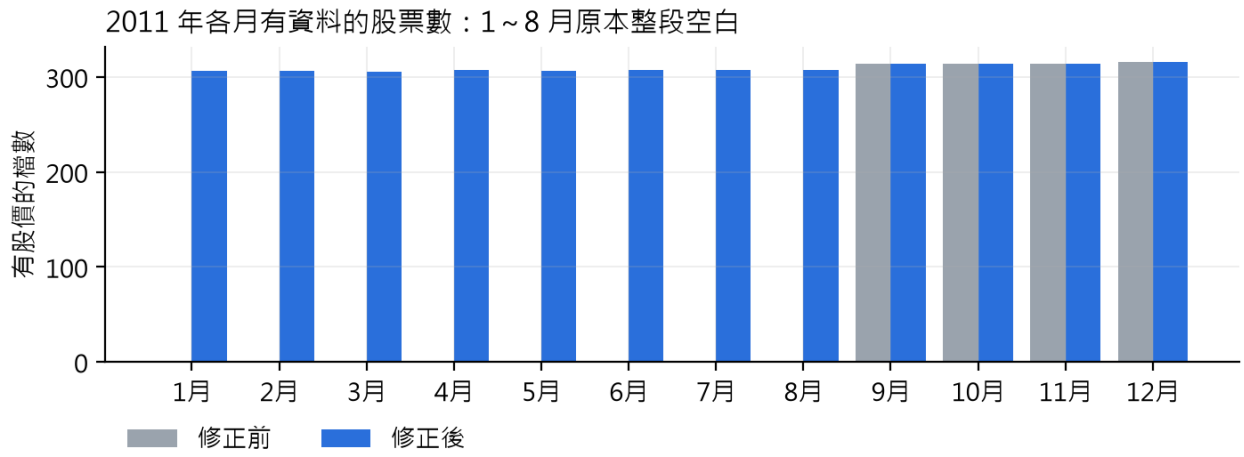
圖六：5 日標籤 + 緩衝帶（m=5）的累積報酬，含下市股、清掉假跳動、扣交易成本、不含現金股利，對數刻度。灰線是加權指數，橘線是加權指數加 3.5% 股利、扣 0.43% 內扣費用，近似持有 0050。

七、大波動日與盤前新聞（2016-10 ~ 2026-10）

- 用滾動標準化定義 142 個大波動日（|z|>2），「當日」只算 t 日開盤前的新聞。
- 大波動日的盤前新聞量明顯較多（國際新聞多約 20%、PTT 多約 52%），負面比例也較高；約一半的大波動日開盤前就看得到「新聞爆量」或「費半前一晚大動」（50.7% vs 一般日 14.2%）。
- 但站在前一天收盤看，新聞量扣掉價格本身的波動群聚後就沒有額外資訊；負面比例有一點點（AUC 0.70 → 0.73），比較像市場緊張度的溫度計，而且完全預測不了方向。
- **新聞空缺已補**：Yahoo 每檔只保留約 200 則，無法往回抓，改用鉅亨補 2025-01 ~ 2026-10 的個股與國際新聞，並重抓被 API 30 頁上限截斷的 17 週。現在 142 個大波動日全部有新聞。另外剔除 2024 年起大量出現的「盤中速報」自動快訊。
- **2025-04 關稅那幾天**：04-07（-9.70%）盤前國際新聞是平常的 3.4 倍、費半前一晚 -7.6%，但開盤就跳空 -5.4%，開盤前知道的事幾乎都在開盤價反映掉了；04-10（+9.25%）是費半前一晚 +18.7% 帶動。關稅新聞那幾天天天都多，分不出哪天跌、哪天漲。
- **關鍵字**：國際新聞的「重挫」在 2025 年後的新資料上仍成立（隔天大波動機率 10.0% vs 2.8%）；之前在 PTT 最強的「戰爭」在新資料上沒有重現。詞表是 AI 挑的，可能帶有事後知識，論文只能寫成限制。

八、資料修正（這次新做的）

- **2011 年 1 ~ 8 月缺價**：316 檔 Yahoo 股價全缺，用證交所 / 櫃買補了 307 檔、50,890 列，重建母體快取與特徵庫，面板最長空白剩 13 天（圖七）。
- **Yahoo 股價不是原始價**：配股和減資會往回調整，現金股利沒算。補值時每檔換算係數，90 檔在除權日切換。
- **下市股換算成同一基準**：除權、減資造成的假跳動，從 -22% ~ +75% 收斂到 ±10% 以內。
- **存活策略全面稽核**：找到假跳動、漲跌停門檻、成交量特徵、季頻出場價四個問題，修正後全部重跑；紀錄在 results/audit/，修正前備份在 results/pre_audit/。
- **季頻重跑後要改的**：逐年表的 2010 年從 -17.9% 變成 +19.8%（原本那一季跨了 9 個月），並新增 2011 年（-27.5%，輸母體）。



圖七：補值前後，2011 年每月有股價資料的股票數。

九、進行中與待決定

- **新聞補資料尚未併入原檔**：2025 年起的鉅亨個股新聞放在 cnyes_news_{code}_2025fill.csv，DAViS 讀新聞的程式暫時讀不到；要併入時執行 news_backfill_2025.py --merge。
- **後續**：DAViS 本體與第七節診斷程式也寫死 10% 漲跌停，不屬於存活策略，尚未修正與重跑。
- **等你決定**：DAViS walk-forward（long11）新舊資料對照。(A) 約 20 小時，最乾淨；(B) 約 10 小時；(C) 不跑。
- **正文待改**：結論總整理的第一、六、七節，以及策略規格文件，要照修正後的數字改寫。

參考文獻

Ang, A., Hodrick, R. J., Xing, Y., & Zhang, X. (2006). The cross-section of volatility and expected returns. Journal of Finance, 61(1), 259–299.（美股的「波動度之謎」，高波動股報酬反而較低，可與本研究台股結果對照）

Benjamini, Y., & Hochberg, Y. (1995). Controlling the false discovery rate: A practical and powerful approach to multiple testing. Journal of the Royal Statistical Society: Series B, 57(1), 289–300.

Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. Journal of Business & Economic Statistics, 13(3), 253–263.

Hansen, P. R. (2005). A test for superior predictive ability. Journal of Business & Economic Statistics, 23(4), 365–380.

Harvey, D., Leybourne, S., & Newbold, P. (1997). Testing the equality of prediction mean squared errors. International Journal of Forecasting, 13(2), 281–291.

López de Prado, M. (2018). Advances in Financial Machine Learning. Hoboken, NJ: Wiley.

Newey, W. K., & West, K. D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. Econometrica, 55(3), 703–708.

Politis, D. N., & Romano, J. P. (1994). The stationary bootstrap. Journal of the American Statistical Association, 89(428), 1303–1313.

White, H. (2000). A reality check for data snooping. Econometrica, 68(5), 1097–1126.

【待補】DAViS 原論文：專案裡找不到完整出處，請補上作者、年份、篇名與出處。

資料來源

臺灣證券交易所：每日收盤行情（MI_INDEX）、個股日成交資訊（STOCK_DAY）、除權除息計算結果表（TWT49U）、減資恢復買賣參考價（TWTAUU）、終止上市公司清單。

證券櫃檯買賣中心：上櫃股票每日收盤行情。臺灣期貨交易所：台指期分時段行情。

Yahoo Finance（歷史股價，配股與減資已分割調整、不含現金股利）；鉅亨網（個股與國際新聞）；PTT 股票板。